



虞凯文

Agent开发

13018992536

杭州

ykw15617426@gmail.com

3 年+ AI 应用开发经验

工作经验

- 四时（杭州）科技有限公司** Agent 应用开发工程师 2025/03 - 2026/09
公司主营袜子及针织服饰，在淘宝、天猫、京东、拼多多运营自有品牌店铺。参与营销内容 Agent 和电商 Multi-Agent 平台开发，支持内容生成、经营分析、售后分析与智能补货。
- 苏州百世威光学技术有限公司** 大模型应用开发工程师 2023/07 - 2025/02
面向 PCB、FPC、IC 载板等外观检测设备业务，参与文本分类和文档问答应用开发，提供业务文本自动归类与设备资料检索能力；RAG 在模拟文档的 96 条固定查询上取得 $\text{Hit}@5 = 1.0$ 、 $\text{MRR}@5 = 0.98$ 的离线检索结果
- 苏州百世威光学技术有限公司** 前端开发工程师 2020/09 - 2023/06
项目面向制造业生产质量管理，设计来料检、首检和巡检页面，并集中展示检验记录及异常处理进度，便于质量人员按批次追溯。

专业技能

大模型应用架构：

- Agent 工作流：**熟悉 LangGraph、LangChain、Tool Calling 和结构化输出；参与设计确定性 Dispatcher 分发 4 类 Agent，并用 Redis Checkpoint 管理状态与恢复。
- RAG 检索系统：**使用 BGE-M3、Milvus、BM25、BGE-Reranker 构建混合检索与精排链路，结合 Parent-Child Chunk、Metadata Filter 定位相关内容。

应用服务化：

- 使用 Python、FastAPI、Pydantic 开发接口与流式问答，具备异常处理和 Docker 部署实践。

模型训练与效果评估：

- NLP 模型训练：**使用 PyTorch、BERT 微调中文文本多分类模型，并以 Precision、Recall、Macro-F1 评估效果。
- 检索质量评估：**构建固定问题集，使用 $\text{Hit}@K$ 、MRR 评估召回与排序效果。

数据处理与工程实践：

- 文档与数据处理：**解析 PDF、Word、Markdown 文档，处理元数据、分块和增量入库。
- 存储与权限治理：**使用 PostgreSQL、MySQL、Redis、MinIO；按 tenant_id、用户角色和 Tool 权限控制数据访问。

● 项目经历

电商智能运营 Multi-Agent 平台

Agent 应用开发工程师

2025/10 - 2026/09

技术栈：Python、FastAPI、LangGraph、Tool Calling、RAG、PostgreSQL、Redis、Milvus、Docker

项目背景：自有品牌商品在多平台、多店铺销售，运营人员需结合订单、销量、库存及售后数据开展工作。随着需求扩展，项目由营销文案 Single Agent 演进为经营分析、营销内容、售后分析和智能补货 4 类 Agent，按职责划分工具与权限，共用数据接入和知识检索能力。

核心职责：

- 架构与分发：参与设计“前端业务入口 → 后端 Dispatcher → 专业 Agent”链路，根据业务域和权限确定目标 Agent；Agent 内部再由 LangGraph 编排 Tool、RAG 与 LLM，顶层不依赖 LLM 进行跨Agent 路由。
- 数据与知识分层：将订单、库存、销售指标等实时结构化数据封装为 Tool；通过 RAG 检索商品知识、业务规则和运营文档，让不同来源的信息在 Agent 流程中按需使用。
- 权限治理：在后端按 tenant_id、用户角色和 Tool 权限范围校验调用及数据访问，限制 Agent 可用能力与可见数据。
- 状态与恢复：使用 LangGraph State、Node、Conditional Edge 管理执行流程，并通过 RedisCheckpoint 保存任务状态，支持异常后的状态追踪与恢复。
- 输出与排障：校验结构化输出的 Schema，记录关键节点、异常信息以便定位问题。

项目亮点：为内部运营团队提供经营分析、营销内容、售后分析和智能补货 4 类业务入口，将订单、销量、库存等实时业务数据与商品资料、活动规则等文档信息结合，为日常经营分析和补货判断提供参考。

电商营销内容 Single Agent

Agent 应用开发工程师

2025/04 - 2025/09

技术栈：Python、FastAPI、LangChain、LangGraph、Tool Calling、RAG、PostgreSQL、Redis、Pydantic

项目背景：自有品牌的袜子、针织品及服饰在多平台上架和促销时，运营人员需结合商品属性、品牌规范及平台规则编写文案。项目通过 Single Agent 串联商品与活动数据查询、规则检索和内容生成，辅助产出商品描述、卖点及活动文案。

核心职责：

- workflow编排：基于 LangGraph 管理商品、活动、渠道和生成任务状态，编排业务数据获取、规则检索、内容生成与结果校验流程；通过 FastAPI 提供服务接口。
- 数据与知识接入：通过 Tool Calling 获取商品、活动等实时业务数据，结合 RAG 检索品牌规范、商品知识及营销规则，使文案生成有明确的事实和规则依据。
- 输出控制：使用 Pydantic / Structured Output 约束生成结果的字段与格式，并为模型调用增加超时、重试处理，便于上层系统接收和运营人员复核。
- 能力复用：将营销内容生成流程沉淀为独立 Agent，参与后续向电商智能运营 Multi-Agent 平台的演进。

项目亮点：将商品与活动数据、品牌及渠道规则接入同一生成流程，输出可供运营人员复核的结构化文案；营销能力后续复用为 Multi-Agent 平台中的独立 Agent。

技术栈：Python、FastAPI、LangChain、BGE-M3、BGE-Reranker、Milvus、BM25、Redis、MySQL、DeepSeekAPI

项目背景：FPC/PCB外观检查设备涉及不同产品系列及检测场景，相关业务文档和操作手册以 PDF、Word、Markdown 等形式分散保存。内部查询既有设备使用类自然语言问题，也有设备系列、型号、文档编号等精确关键词。项目将文档构建为可检索知识库，结合混合检索与精排为问答提供依据，并处理文档重复入库与版本更新。

核心职责：

- 处理 PDF、Word、Markdown 等文档，标准化 Metadata 并采用 Parent-Child Chunk：用 Child Chunk 提高召回精度，用 Parent Chunk 补充回答上下文。
- 使用 BGE-M3 构建 Dense / Sparse 表示，通过 Milvus Hybrid Search 召回候选，结合 BGEReranker 精排；以 BM25 补充型号、编号等关键词查询，并用 Metadata Filter 限定检索范围。
- 编排检索，证据整理，提示词构建和大模型生成过程，实现来源引用，答案与证据一致性校验，实现可信答案生成
- 使用 SHA-256 生成稳定的 Child Chunk ID，结合 Milvus upsert 处理重复入库；按文档指纹及新旧 Chunk ID 差集设计增量更新流程。
- 基于FastAPI开发普通问答与SSE流式接口, 使用Redis缓存重复问题的结果, 并从MySql查询报警定义, 为前端提供结构化参考信息。

项目亮点：结合设备型号过滤、BGE-M3 混合检索与 BM25 处理自然语言和精确编号查询；96 条固定查询上，混合检索阶段达到 Hit@5 = 1.0、MRR@5 = 0.98。

技术栈：Python、PyTorch、Transformers、BERT、Scikit-learn、FastAPI、MySQL

项目背景：围绕 AVI-600L、AVI-800Z 等外观检测设备的使用反馈、检测异常和售后问题，构建业务文本分类系统，将非结构化描述转为统一标签，支持问题归类、分流与分类统计。

核心职责：

- 参与业务文本清洗、标签体系整理及训练数据构建，基于 bert-base-chinese 进行文本多分类模型微调。
- 使用 Precision、Recall、Macro-F1 评估分类效果，分析类别不均衡、错误样本及输入长度等问题。
- 通过 FastAPI 封装模型推理接口，并参与与 MySQL 及上层业务系统的联调。

项目成果：打通文本清洗、BERT 多分类微调、错误样本分析和 FastAPI 推理接口，让设备相关业务文本输出统一标签，支持后续检索与处理。

教育经历